

بخش ۱: وارد کردن کتابخانه‌ها

```
import pandas as pd

import matplotlib.pyplot as plt

import seaborn as sns
```

- ◆ pandas: برای خواندن، بررسی و پردازش داده‌های جدولی (DataFrame).
 - ◆ matplotlib.pyplot: برای رسم نمودارهای ساده مانند Bar، Scatter، Pie و...
 - ◆ seaborn: برای رسم نمودارهای آماری پیشرفته‌تر مانند Violin Plot و Heatmap.
-

بخش ۲: خواندن و پیش‌پردازش داده‌ها

```
df = pd.read_csv('footballds.csv')
```

- ◆ فایل CSV با نام footballds.csv خوانده می‌شود و در قالب یک دیتافریم (df) ذخیره می‌شود.

```
df['goals'] = pd.to_numeric(df['goals'], errors='coerce')
df['assists'] = pd.to_numeric(df['assists'], errors='coerce')
df['rating'] = pd.to_numeric(df['rating'], errors='coerce')
df['age'] = pd.to_numeric(df['age'], errors='coerce')
df['position'] = df['position'].astype(str)
```

♦ ستون‌های عددی به نوع عددی (numeric) تبدیل می‌شوند. اگر مقداری غیرقابل تبدیل باشد، تبدیل به NaN می‌شود.

♦ ستون position هم به رشته تبدیل می‌شود.

```
df_filtered = df.dropna(subset=['goals', 'position'])
```

♦ تمام ردیف‌هایی که مقدار goals یا position آن‌ها خالی (NaN) است، حذف می‌شوند.

بخش ۳: رسم نمودارها 📌

1. نمودار میله‌ای - مجموع گل‌ها بر اساس پوزیشن

```
plt.figure(figsize=(10,6))
```

```
goals_by_position = df_filtered.groupby('position')['goals'].sum()
```

```
goals_by_position.plot(kind='bar', color='skyblue')
```

```
plt.title('Total Goals by Position', fontsize=14)
```

```
plt.xlabel('Position', fontsize=12)
```

```
plt.ylabel('Total Goals', fontsize=12)
```

```
plt.xticks(rotation=45)
```

```
plt.grid(True)
```

```
plt.tight_layout()
```

```
plt.show()
```

◆ این نمودار مجموع گل‌ها برای هر پوزیشن (مهاجم، هافبک و...) را نمایش می‌دهد.

2. نمودار پراکندگی - (Scatter Plot) گل‌ها نسبت به سن

```
plt.figure(figsize=(8, 6))  
  
plt.scatter(df['age'], df['goals'], alpha=0.6, color='green')  
  
plt.title('Scatter Plot: Goals vs Age')  
  
plt.xlabel('Age')  
  
plt.ylabel('Goals')  
  
plt.grid(True)  
  
plt.tight_layout()  
  
plt.show()
```

◆ بررسی می‌شود که بازیکنان در چه سنی بیشتر گل می‌زنند. هر نقطه نمایانگر یک بازیکن است.

3. نمودار جدید - هیستوگرام تعداد بازیکنان بر اساس تعداد گل

```
plt.figure(figsize=(10,6))  
  
plt.hist(df['goals'].dropna(), bins=15, color='orange', edgecolor='black')  
  
plt.title('Histogram of Goals Scored')
```

```
plt.xlabel('Goals')  
plt.ylabel('Number of Players')  
plt.tight_layout()  
plt.show()
```

◆ این نمودار نشان می‌دهد چه تعداد بازیکن چند گل زده‌اند (توزیع تعداد گل‌ها).

4. نمودار - BoxPlot ریتینگ بر اساس پوزیشن

```
plt.figure(figsize=(10,6))  
sns.boxplot(data=df, x='position', y='rating', palette='pastel')  
plt.title('Boxplot of Rating by Position')  
plt.xlabel('Position')  
plt.ylabel('Rating')  
plt.xticks(rotation=45)  
plt.tight_layout()  
plt.show()
```

◆ برای هر پوزیشن، محدوده پراکندگی امتیاز (Rating) بازیکنان نمایش داده می‌شود.

5. نمودار دایره‌ای - (Pie) درصد بازیکنان در هر پوزیشن

```
plt.figure(figsize=(8, 8))

position_counts = df['position'].value_counts()

plt.pie(position_counts, labels=position_counts.index, autopct='%1.1f%%',
        startangle=140, colors=sns.color_palette('Set2'))

plt.title('Player Distribution by Position')

plt.axis('equal')

plt.tight_layout()

plt.show()
```

♦ درصد بازیکنان در هر پوزیشن را نمایش می‌دهد.

6. نمودار - Violin توزیع ریتینگ بازیکنان بر اساس پوزیشن

```
plt.figure(figsize=(12, 6))

sns.violinplot(data=df, x='position', y='rating', palette='Set3')

plt.title('Distribution of Ratings by Position')

plt.xlabel('Position')

plt.ylabel('Rating')

plt.xticks(rotation=45)

plt.tight_layout()
```

```
plt.show()
```

♦ ترکیبی از BoxPlot و KDE که شکل دقیق‌تری از توزیع امتیاز بازیکنان در پوزیشن‌های مختلف نشان می‌دهد.

7. نمودار - Heatmap همبستگی بین ویژگی‌ها

```
plt.figure(figsize=(8, 6))
```

```
correlation = df[['goals', 'assists', 'rating', 'age']].corr()
```

```
sns.heatmap(correlation, annot=True, cmap='coolwarm', fmt=".2f",  
            square=True)
```

```
plt.title('Correlation Heatmap')
```

```
plt.tight_layout()
```

```
plt.show()
```

♦ این نمودار همبستگی (رابطه) بین متغیرهای عددی را نمایش می‌دهد.

بخش ۴: بررسی و پاکسازی مقادیر گمشده (Nulls) 

درصد مقادیر گمشده

```
total_null = df.isnull().sum().sum()
```

```
total_cells = df.size
```

```
null_percentage = (total_null / total_cells) * 100
```

```
print(f'all null: {null_percentage:.2f}%")
```

♦ درصد کل سلول‌های گم‌شده را محاسبه می‌کند.

```
null_percentage_per_column = (df.isnull().sum() / len(df)) * 100
```

```
print("Null percentage per column:\n",  
      null_percentage_per_column.round(2))
```

♦ درصد مقادیر گم‌شده برای هر ستون را نشان می‌دهد.

بخش ۵: پر کردن مقادیر گم‌شده

```
df['position'].fillna('Unknown', inplace=True)
```

♦ مقدارهای خالی در پوزیشن به "Unknown" تبدیل می‌شود.

```
df['position_encoded'] = df['position'].astype('category').cat.codes
```

♦ پوزیشن‌ها به صورت عددی کدگذاری می‌شوند.

پر کردن مقدار assists بر اساس میانگین هر تعداد گل

```
goals_assist_avg = df.groupby('goals')['assists'].mean()
```

```
def fill_assists(row):
```

```
    if pd.isnull(row['assists']):
```

```
        return goals_assist_avg.get(row['goals'], df['assists'].mean())
```

```
    else:
```

```
return row['assists']
```

```
df['assists'] = df.apply(fill_assists, axis=1)
```

◆ اگر مقدار assist خالی باشد، میانگین assist برای همان تعداد گل را جایگزین می‌کند.

پُر کردن مقدار rating بر اساس میانگین ترکیبی گل و assist

```
grouped_avg = df.groupby(['goals', 'assists'])['rating'].mean()
```

```
def fill_rating(row):
```

```
    if pd.isnull(row['rating']):
```

```
        return grouped_avg.get((row['goals'], row['assists']), df['rating'].mean())
```

```
    else:
```

```
        return row['rating']
```

```
df['rating'] = df.apply(fill_rating, axis=1)
```

◆ اگر امتیاز بازیکن خالی باشد، از میانگین بازیکنانی با تعداد گل و پاس مشابه استفاده می‌شود.

پُر کردن مقدار club با حالت رایج‌تر در همان پوزیشن

```
position_club_mode = df.groupby('position')['club'].agg(lambda x:  
    x.mode().iloc[0] if not x.mode().empty else None)
```

```
def fill_club(row):
```



```
if pd.isnull(row['club']):  
    return position_club_mode.get(row['position'], df['club'].mode()[0])  
    else:  
        return row['club']  
df['club'] = df.apply(fill_club, axis=1)
```

◆ اگر نام باشگاه بازیکن خالی باشد، رایجترین باشگاه برای آن پوزیشن جایگزین می‌شود.

بخش آخر: ذخیره فایل تمیزشده 📌

```
df_cleaned = df.dropna()  
df_cleaned.to_excel("cleaned_dataset.xlsx", index=False)  
print("cleaned_dataset.xlsx successfully saved")
```

◆ تمام ردیف‌های باقی‌مانده با مقدارهای کامل در فایل Excel ذخیره می‌شود.